



Парсер САЗ як окремий сервіс


UKMA Data: що будуємо і як парсимо

Жовтень 2026, data.rateukma.com (робоча назва)



Проблема


Записи з САЗ у Rate UKMA востаннє імпортували 5 липня:
парсер запускає розробник руками, і це 2-3 години.



Сервіс оновлюватиме дані сам і показуватиме, що змінилося.

Дані вже є, але парсимо їх двічі

Rate UKMA уже парсить картки, семестри і курси з 2018 року,
а UKMA Schedule окремо парсить ті самі сторінки.




Не пишемо з нуля: зводимо обидва парсери в один сервіс з API.

Що вже вирішили

Тема	Рішення
Читачі	Кожен читач рівний, Rate UKMA теж. Нема запитів під одного читача
Парсинг	За розкладом. Позачерговий прохід за правом runs:trigger, рідко
Rate UKMA	Повна копія, синхронізація раз на добу
Студенти	Усі роки з САЗ, ПІБ і email за правом students:read
Мова	TypeScript і Effect 4
Репозиторій	Монорепо rate-ukma, своя папка і своя база
Інфраструктура	Kubernetes на Hetzner через Terraform, staging і prod окремо (#705)
Адреса	Піддомен rateukma.com, робоча назва data.rateukma.com
Доступ	Список прав на кожному ключі, без ролей; ключі створює тільки адмін
Курси через роки	Групує сервіс, старт з груп Rate UKMA
Адмінка	HTML із сервера на Effect і htmx

Як це влаштовано




Пише в базу тільки воркер, а читають усі тільки через API.

Джерела

Джерело	Що беремо	Вхід	Як часто
САЗ	каталог, сторінки курсів: картка і список записаних	Microsoft, далі cookie	щогодини під час запису, щодня поза ним
smart.ukma	викладачі, їхні дисципліни	Microsoft, далі токен	щодня
Файли розкладу	пари й аудиторії	без входу	можливо, пізніше

Нове джерело це нова папка з чотирма частинами: вхід, що забирати, розбір, перетворення в наші записи.

Як парсимо САЗ



Сторінка курсу одна, але список на ній браузер довантажує окремим запитом. Ми робимо ті самі два запити: 4 курси паралельно, 150 мс між запитами

Беремо парсер UKMA Schedule: він уже бере картку і список за один захід на курс.

Картка курсу: що забираємо

Код	123456
Навчальний рік	2026-2027
Статус	можливо
Кафедра	Кафедра інформатики
Рік навчання	2
Викладач	Петренко О. І., доцент
Спеціальності	ІПЗ, обов'язкова
Осінь	4 кр, 3 год/тиж, залік
Весна	4 кр, 3 год/тиж, екзамен
Ліміт	60 студентів, 3 групи

```
{
  "sazCode": "123456",
  "title": "Бази даних",
  "academicYear": 2026,
  "status": "PENDING",
  "level": "BACHELOR",
  "studyYear": 2,
  "teacherText": "Петренко О. І., доцент",
  "limits": { "maxStudents": 60, "maxGroups": 3 },
  "programmes": [
    { "name": "Інженерія програмного забезпечення",
      "kind": "COMPULSORY" }
  ],
  "terms": [
    { "term": "2026-27-FALL", "credits": 4,
      "hoursPerWeek": 3, "assessment": "CREDIT" },
    { "term": "2026-27-SPRING", "credits": 4,
      "hoursPerWeek": 3, "assessment": "EXAM" }
  ]
}
```



Значення вигадані, поля справжні

Список записаних

Список це частина сторінки курсу: 17 полів на кожного студента, разом з ПІБ і email.

CA3 віддає

name, email, cdoc, grade, specName, group, status, statusLabel, isStudentActive, isEnrolled, isUnenrolled, isForced, type, typeLabel, createdAt, updatedAt, statusDescription

Ми зберігаємо, значення вигадані

```
{  
  "email": "o.testenko@ukma.edu.ua",  
  "lastName": "Тестенко",  
  "firstName": "Олена",  
  "middleName": "Іванівна",  
  "status": "ENROLLED",  
  "kind": "ELECTIVE",  
  "group": "1",  
  "programme": "prg_01k6..."  
}
```

Зберігаємо всю відповідь, а ПІБ і email віддаємо тільки ключам з правом students:read.

Як парсимо smart.ukma

smart.ukma має REST API з описом в OpenAPI, і ПІБ викладачів там уже розділені.

839 викладачів

8 195 зв'язків викладач і дисципліна

11 033 дисципліни

5,5 с повна вибірка зв'язків

Беремо викладачів, їхні ролі і дисципліни щодня.

```
GET /api/teacher/disciplines
    ?restrict={"limit":1000,"offset":0}
Authorization: Bearer <токен зі сторінки>
```

Вхід такий самий, як у САЗ, токен беремо зі сторінки після входу

Як зв'язати викладача з курсом

Спільного коду між сайтами нема, optimaCode для цього не підходить: за назвою пару мають 72% курсів.

1. Назва

назва, кафедра, семестр, кредити
57% курсів отримують викладача

2. Викладач з картки

текст «Викладач» із САЗ проти ПІБ зі
smart.ukma
покриття ще не міряли


3. Вручну

адмін виправляє в адмінці
має пріоритет над усім

Кожен зв'язок зберігає, як його знайшли і наскільки ми впевнені.

Спочатку знімок сторінки

Без збережених сторінок кожне нове поле означає знову пройти 24 124 картки САЗ.



Спершу зберігаємо знімок, потім розбираємо його, тому перерахунок не ходить у САЗ.


Знімок, а не сирий HTML

Сирий HTML CA3 інший у кожній відповіді через токен безпеки, тому «зберігати тільки зміни» з ним не працює.

	Сирий HTML	Знімок сторінки
Одна картка	18 КБ, стиснуто 5,5 КБ	1,6 КБ, стиснуто 0,6 КБ
Тільки зміни	ні, хеш щоразу інший	так, міняється разом з даними
Прохід щогодини, 3 050 карток	17 МБ щоразу, 400 МБ на добу	тільки змінені картки
Усі 24 124 картки	130 МБ на кожну версію	14 МБ на першу версію
Новий парсер чи поле	без CA3	без CA3, якщо поле є на сторінці
Чистити	треба	не треба

Зберігаємо знімок, а сирий HTML тільки тоді, коли розбір упав.

Модель даних



Центр моделі це Offering: одна картка курсу в САЗ на один навчальний рік.

Модель: каталог

Сутність	Що це	Основні поля
Term	семестр	2026-27-FALL , academicYear, season
Faculty	факультет	name, abbreviation
Department	кафедра	faculty, name
Programme	освітня програма	name, level: BACHELOR чи MASTER
Course	предмет через роки	групу задає правило або адмін, назва з останньої картки
Offering	картка САЗ на рік	sazCode, academicYear, title, department, level, status, studyYear, limits, annotation, teacherText
OfferingTerm	семестр курсу	term, credits, hoursPerWeek, lectures, practice, assessment
OfferingProgramme	роль для програми	programme, kind: COMPULSORY, PROF_ORIENTED, ELECTIVE

У кожної сутності свій id і мітки first_seen, last_seen, removed



Модель: люди, проходи, рішення

Сутність	Що це	Основні поля
Instructor	викладач зі smart.ukma	lastName, firstName, middleName, department, email
OfferingInstructor	хто веде курс	role: LECTURER, PRACTICE, BOTH; method; confidence
Student	студент	email, lastName, firstName, middleName, programme, studyYear, active
Enrollment	запис на курс	student, status: ENROLLED, DROPPED, FORCED; kind; group; enrolledAt
Run	один прохід воркера	source, resource, status: PUBLISHED, HELD, FAILED; лічильники
Change	одна зміна в даних	seq, run, entity, op: ADDED, CHANGED, REMOVED; було і стало
PageSnapshot	знімок сторінки	source, url, sha256, fetchedAt, body
Override	рішення адміна	target, action: MERGE, SPLIT, MOVE, LINK; reason

Student і Enrollment віддаємо тільки з правом students:read

Один курс, два семестри

Rate UKMA зберігає всі семестри картки, але фільтр за семестром дивиться лише на останній: восени 2026 він не знаходить 194 з 1 308 курсів.

Картка СА3 362858

осінь 2026: 2,5 кр, залік
весна 2027: 2,5 кр, екзамен

База Rate UKMA

обидва семестри є
семестр картки: весна

Фільтр «осінь 2026»


курсу **нема**
«весна 2027» знаходить

Українська мова за професійним спрямуванням, 63 оцінки: [картка в СА3](#), [курс у Rate UKMA](#), фільтри [осінь](#) і [весна](#)

Сервіс віддає семестри так, як їх зберігає Rate UKMA, але без поля «семестр картки».

Курси через роки


У Rate UKMA курс це однакова назва, кафедра і рівень, тому «Бази даних» склеїли два різні предмети.



Сервіс стартує з груп Rate UKMA і сам нічого не переносить: злиття і поділ робить адмін.

Ідентифікатори


Наш id не змінюється, навіть якщо джерело змінить свій.



Id джерел лишаються ключами для пошуку: `/v1/offerings?sazCode=123456`.

Оновлення і журнал змін

Зламаний прохід не має дійти до читачів.



Приклад: прохід бачить набагато менше курсів, ніж минулий, тому чекає на адміна і нічого не змінює

Кожна зміна йде в журнал, і читачі синхронізуються з нього: `GET /v1/changes?after=4810`.

Адмінка

Видно кожен прохід і що саме він змінив.

Прохід	Джерело	Що	Коли	Стан	+ / ~ / -
run_01k6...	CA3	курси 2026-27	3 жов, 06:00	застосовано	12 / 448 / 23
run_01k6...	smart.ukma	викладачі	3 жов, 05:00	застосовано	4 / 9 / 0
run_01k5...	CA3	курси 2026-27	2 жов, 06:00	чекає	0 / 3 / 2104
run_01k5...	CA3	курси 2026-27, позачергово	1 жов, 14:10	застосовано	0 / 61 / 5

Значення вигадані. Клік на прохід показує зміни поле за полем: було і стало

HTML із того самого сервера на Effect, дії через htmx, вхід за ключем адміна.

API

Запит	Що віддає	Право
GET /v1/terms , /faculties , /departments , /programmes	довідники	catalog:read
GET /v1/courses , /courses/{id}	курси з картками за роки	catalog:read
GET /v1/offerings?term=&programme=&sazCode=	картки з семестрами і програмами	catalog:read
GET /v1/instructors , /offerings/{id}/instructors	викладачі і хто що веде	instructors:read
GET /v1/students , /v1/enrollments	студенти з ПІБ і їхні записи	students:read
GET /v1/changes?after=	журнал змін, тільки те, що ключ може читати	будь-який ключ
GET /v1/runs	проходи і свіжість даних	будь-який ключ
POST /v1/runs	позачерговий прохід	runs:trigger

Тільки читання, крім позачергового проходу. OpenAPI генеруємо з коду, зміна, що ламає читачів, йде в /v2

Ключі і права

Ключ несе свій список прав, і кожен запит перевіряє одне право. Ролей нема.

Право	Що дає
catalog:read	семестри, факультети, програми, курси, картки
instructors:read	викладачі з email і хто що веде
students:read	студенти і їхні записи
runs:trigger	позачерговий прохід
admin	адмінка: ключі, аудит, рішення, знімки; включає всі інші права

```
$ ukma-data keys create --name rate-ukma --expires 2027-09-01 \  
  --scopes catalog:read,instructors:read,students:read,runs:trigger
```

Нова комбінація прав це новий ключ, а не зміна коду.

Персональні дані


Сервіс зберігатиме ПІБ, email і курси всіх студентів, яких показує САЗ, за всі роки.

- **ПІБ і email** віддаємо тільки з правом students:read
- **Знімки сторінок** бачать тільки адміни
- **Справжніх даних** нема у фікстурах, логах і задачах

Кожне читання студентів видно в аудиті.

Rate UKMA як читач

Rate UKMA тримає повну копію і раз на добу бере зміни, тому працює, навіть коли сервіс лежить.



Rate UKMA отримує команду синхронізації, а папка scraper/ зникає.

Де сервіс живе в монорепо

У Rate UKMA деплой розкиданий по `src/`, `infra/`, `scripts/` і `docs/`, а новий сервіс має жити в одній папці.

1. Усе в папці сервісу

```
src/  
  backend/  
  webapp/  
  ukma-data/  
    src/ test/  
    deploy/  
    k8s/  
    terraform/  
  docs/
```

Як backend і webapp. Видалити сервіс
це одна папка

2. Кластер окремо

```
src/  
  backend/  
  webapp/  
  ukma-data/  
    src/ test/  
    deploy/k8s/  
    docs/  
infra/  
  nginx/  
  terraform/
```

Готово, коли на кластер переїде і Rate
UKMA

3. Усе в apps/

```
apps/  
  rate-ukma-api/  
  rate-ukma-web/  
  ukma-data/  
    deploy/  
    docs/  
infra/  
docs/
```

Однаково для всіх, але переносимо
весь Rate UKMA зараз

Пропоную перший, а Terraform винесемо в `infra/`, коли кластер стане спільним.

Всередині src/ukma-data

Нове джерело це нова папка в sources/ з чотирма файлами, решта спільна.

```
src/ukma-data/  
├─ src/  
│   ├── sources/  
│   │   ├── saz/          login, plan, parse, map  
│   │   └─ smart-ukma/    login, plan, parse, map  
│   ├── pipeline/         знімок, порівняння, перевірка, журнал змін  
│   ├── domain/           схеми: Offering, Course, Student...  
│   ├── grouping/         курси через роки, рішення адміна  
│   ├── api/              /v1, ключі, права  
│   ├── admin/            HTML i htmx  
│   └─ cli.ts             keys create, runs start  
├─ migrations/  
├─ test/                 фікстури тільки з вигаданими даними  
├─ deploy/               k8s/, terraform/  
├─ docs/                 spec.md, deployment.md  
├─ Dockerfile  
└─ package.json
```

CI для сервісу запускається тільки на зміни в src/ukma-data/.

План до 1 грудня

1. Каркас

Сервер, база, ключі, один запит, OpenAPI у CI, деплой у staging

2. САЗ

Знімки сторінок за всі роки, парсер, журнал змін, перевірка, адмінка

Сервіс: Андрій Валеня. Інфраструктура: Анастасія Алексеєнко (#705)

3. Rate UKMA читає API

Повна копія раз на добу, старий парсер видалено

4. Викладачі

smart.ukma, зв'язок з курсами, виправлення в адмінці

Відкриті питання

1. Чи увійде воркер без людини: MFA, скільки живуть сесія і токен?
2. Назва: data.rateukma.com підходить?
3. Хто підтримує сервіс після курсу?





Дякую. Питання?

data.rateukma.com, робоча назва

Ця презентація зроблена з ШІ та вчитана людьми)

